

# Rede Intelectual da DBpedia

Aplicação de PageRank e análise estrutural em um grafo de conhecimento

Raphael Salles Vitor de Souza (RA 223641)

Lucas Félix (RA 247064)

MC859 — Projeto em Teoria da Computação

Prof. Ruben Interian Kovaliova — Universidade Estadual de Campinas

22 de junho de 2026

**Implementação pública:**

<https://github.com/RaphaelSVSouza/mc859-dbpedia-intellectual-network>

## 1 Introdução

Grafos de conhecimento representam entidades como vértices e relações semânticas como arestas. Essa estrutura permite estudar não apenas os atributos isolados de uma entidade, mas também sua posição em uma rede de relações. A DBpedia é especialmente adequada a esse tipo de análise porque extrai informação estruturada da Wikipédia e a disponibiliza como dados ligados, reunindo entidades de diferentes domínios em uma base de conhecimento aberta [1].

Este trabalho construiu uma rede intelectual a partir da DBpedia, concentrando-se em relações de influência, orientação acadêmica, formação, áreas de atuação, obras, religião e ideologia. A hipótese investigada é que a estrutura dessas relações contém sinais capazes de distinguir entidades relevantes e de recuperar parte da organização semântica presente no domínio. Em vez de considerar toda a DBpedia, foi produzido um subgrafo temático direcionado, adequado à execução de algoritmos de centralidade em hardware acadêmico convencional.

A análise foi dividida em três partes. Primeiro, estudaram-se propriedades estruturais do grafo, como distribuição de graus e componentes fortemente conexas. Em seguida, aplicou-se PageRank ao grafo de treino em três projeções distintas: um baseline heterogêneo, uma projeção voltada a pessoas e uma projeção institucional. Por fim, o Personalized PageRank foi empregado em um experimento de predição de arestas.

### 1.1 Objetivo geral

Construir e analisar um grafo de conhecimento direcionado, derivado da DBpedia, para investigar em que medida sua topologia permite identificar entidades intelectualmente relevantes e recuperar relações ocultas do grafo.

### 1.2 Objetivos específicos

- extrair do dump da DBpedia um subconjunto de relações associadas à rede intelectual;
- normalizar a orientação semântica de relações inversas e eliminar triplas duplicadas;
- serializar o grafo nos formatos N-Triples, GEXF e GraphML;
- instanciar o grafo no Neo4j e projetá-lo com o Graph Data Science;
- caracterizar sua estrutura por métricas de grau e conectividade;
- comparar variantes do PageRank voltadas a pessoas e instituições;
- avaliar os rankings obtidos por meio de referências externas;
- avaliar o Personalized PageRank como método de predição de ligações.

## 2 Aquisição e preparação dos dados

### 2.1 Fonte dos dados

A coleta utilizou o arquivo `mappingbased-objects_lang=en.ttl.bz2`, correspondente ao componente *mapping-based objects* em inglês da DBpedia, no snapshot de 1º de dezembro de 2022 [2]. Esse dump contém triplas RDF extraídas principalmente das infocaixas da Wikipédia. Cada registro segue a forma  $\langle s, p, o \rangle$ , na qual  $s$  é o recurso de origem,  $p$  é o predicado e  $o$  é outro recurso identificado por URI.

O dump utilizado continha 22.791.171 triplas. Como o objetivo não era reproduzir toda a DBpedia, foram selecionados 11 predicados relacionados à circulação de influência e à caracterização intelectual: `influencedBy`,

influenced, doctoralAdvisor, doctoralStudent, academicAdvisor, almaMater, knownFor, notableWork, field, religion e ideology.

A filtragem foi feita por correspondência literal com `grep -F`, utilizando a lista versionada em `pipeline/preds.txt`. Esse procedimento reduziu o conjunto para 432.975 triplas.

## 2.2 Reorientação das relações

Predicados inversos podem representar a mesma relação com direções opostas. Para estabelecer uma convenção única, três relações foram reescritas:

$$\begin{aligned}\text{influencedBy}(A, B) &\longrightarrow \text{influenced}(B, A), \\ \text{doctoralAdvisor}(A, B) &\longrightarrow \text{doctoralStudent}(B, A), \\ \text{academicAdvisor}(A, B) &\longrightarrow \text{academicStudent}(B, A).\end{aligned}$$

Assim, as arestas de influência e orientação passaram a apontar do influenciador ou orientador para a pessoa influenciada ou orientada. A transformação foi implementada com `awk`, trocando sujeito e objeto quando o predicado pertencia ao conjunto de relações inversas.

Como a DBpedia pode registrar simultaneamente uma relação direta e sua inversa, a reorientação gera triplas coincidentes. Um `sort -u` foi então utilizado para deduplicar o resultado. Foram removidas 6.358 ocorrências redundantes, equivalentes a aproximadamente 1,47% das triplas filtradas. Embora tenham sido selecionados 11 predicados na entrada, a normalização produziu nove tipos finais de relação, pois os predicados inversos foram incorporados aos seus equivalentes canônicos.

**Tabela 1:** Quantidade de triplas nas etapas de preparação.

| Etapa | Operação                                    | Triplas    |
|-------|---------------------------------------------|------------|
| 0     | Dump <i>mapping-based objects</i> em inglês | 22.791.171 |
| 1     | Filtragem pelos 11 predicados               | 432.975    |
| 2     | Reorientação das relações inversas          | 432.975    |
| 3     | Deduplicação                                | 426.617    |

## 2.3 Composição do grafo final

O grafo final contém 326.270 vértices e 426.617 arestas direcionadas. A Tabela 2 mostra a participação de cada tipo de relação. `almaMater` representa mais da metade das arestas, enquanto `knownFor` responde por 19,00%. Essa assimetria é importante para interpretar os rankings: no grafo completo, instituições de ensino e objetos associados a relações muito frequentes recebem uma parcela considerável do fluxo de prestígio.

**Tabela 2:** Distribuição das arestas por predicado após a normalização.

| Predicado final              | Arestas | Participação |
|------------------------------|---------|--------------|
| <code>almaMater</code>       | 220.232 | 51,62%       |
| <code>knownFor</code>        | 81.055  | 19,00%       |
| <code>religion</code>        | 30.421  | 7,13%        |
| <code>ideology</code>        | 27.521  | 6,45%        |
| <code>influenced</code>      | 22.936  | 5,38%        |
| <code>doctoralStudent</code> | 16.237  | 3,81%        |
| <code>field</code>           | 13.586  | 3,18%        |
| <code>notableWork</code>     | 11.933  | 2,80%        |
| <code>academicStudent</code> | 2.696   | 0,63%        |

## 2.4 Serialização e reprodutibilidade

O resultado deduplicado foi salvo em N-Triples e convertido para GEXF pelo script `pipeline/nt_to_gexf.py`. Durante a conversão, cada URI recebeu um identificador numérico, os nomes legíveis foram derivados

do trecho final das URIs e os predicados foram armazenados como rótulos das arestas. O wrapper `pipeline/run_pipeline.py` também permite gerar GraphML por meio da biblioteca NetworkX.

O repositório contém os comandos de filtragem, os scripts de conversão e os programas de análise. Dessa forma, o grafo pode ser regenerado de maneira determinística a partir do snapshot indicado da DBpedia. Os arquivos de maior volume também foram disponibilizados separadamente para evitar que a reprodução dependa da etapa mais demorada de processamento do dump original.

### 3 Estrutura da rede intelectual

A caracterização inicial foi realizada com o script `analysis/analise_graph.py`, que lê o GEXF como um grafo direcionado e calcula graus de entrada e saída e componentes fortemente conexas. As métricas resultantes são apresentadas na Tabela 3.

**Tabela 3:** Métricas estruturais do grafo.

| Métrica                            | Valor            |
|------------------------------------|------------------|
| Vértices                           | 326.270          |
| Arestas direcionadas               | 426.617          |
| Grau médio total                   | 2,6151           |
| Grau médio de entrada              | 1,3076           |
| Grau médio de saída                | 1,3076           |
| Maior grau de entrada              | 4.068            |
| Maior grau de saída                | 237              |
| Componentes fortemente conexas     | 325.240          |
| Maior componente fortemente conexa | 840 vértices     |
| Componentes unitárias              | 325.127 (99,97%) |

#### 3.1 Distribuição dos graus

A distribuição observada apresenta uma cauda pesada: a maior parte dos vértices tem poucas conexões, enquanto um conjunto reduzido funciona como *hub*. O maior grau de entrada é 4.068, muito superior ao grau médio total de 2,6151. Entre os vértices de alto grau de entrada aparecem instituições, religiões e áreas do conhecimento, resultado compatível com a frequência de relações como `almaMater`, `religion` e `knownFor`.

Essa heterogeneidade sugere uma estrutura favorável à diferenciação por centralidade. Entretanto, a aparência aproximadamente linear do gráfico em escala log-log não é suficiente, isoladamente, para demonstrar que a distribuição segue uma lei de potência; uma conclusão desse tipo exigiria ajuste e teste estatístico específicos. Neste trabalho, a figura é utilizada apenas como evidência descritiva da concentração de conexões.

#### 3.2 Componentes fortemente conexas


Uma componente fortemente conexa é um conjunto de vértices no qual cada vértice pode alcançar todos os demais respeitando a orientação das arestas. O grafo contém 325.240 componentes desse tipo, das quais 325.127 são unitárias. A maior componente possui 840 vértices.

A fragmentação é coerente com a semântica temporal e hierárquica de parte das relações. Arestas de orientação e influência tendem a seguir do orientador para o aluno ou de uma figura anterior para uma posterior, enquanto `almaMater` liga pessoas a instituições. Essas direções raramente formam caminhos de retorno, produzindo uma rede predominantemente acíclica. A consequência metodológica é relevante: algoritmos baseados em caminhadas aleatórias, principalmente quando executados em projeções restritas, podem alcançar somente uma parcela limitada do grafo a partir de determinada origem.


#### 3.3 Visualização do núcleo estrutural

Para produzir uma visualização legível, foi extraído um subgrafo em três etapas: seleção dos 500 vértices de maior grau no grafo completo, remoção dos vértices com grau inferior a 2 dentro desse subconjunto e escolha da maior componente fracamente conexa remanescente. O resultado contém 19 vértices e 60 arestas. A redução não foi utilizada no cálculo dos rankings; sua finalidade foi exclusivamente exploratória e visual.

O núcleo resultante é apresentado na Figura 3a, em conjunto com a amostra global produzida posteriormente no Neo4j Browser.



**Figura 1:** Distribuição do grau total em escala log-log. A maior parte dos vértices apresenta grau baixo, enquanto poucos hubs concentram grande número de relações.



**Figura 2:** Distribuição dos tamanhos das componentes fortemente conexas. Observa-se predominância de componentes unitárias e uma maior componente com 840 vértices.

## 4 Instanciação no Neo4j

O grafo foi instanciado no Neo4j seguindo o modelo de grafo de propriedades. Cada recurso RDF foi representado por um nó com o rótulo **Resource** e duas propriedades principais: **uri**, que preserva seu identificador original, e **label**, que armazena uma forma legível do nome. Cada predicado foi convertido em um tipo de relacionamento em letras maiúsculas. Por exemplo,

```
<http://dbpedia.org/resource/Albert_Einstein>
<http://dbpedia.org/ontology/influenced>
<http://dbpedia.org/resource/Niels_Bohr> .
```

é representado como:


```
(Albert Einstein)-[:INFLUENCED]->(Niels Bohr)
```

O banco pode ser preparado de duas maneiras. Na primeira, utiliza-se o Neo4j Desktop: é possível criar uma instância vazia, instalar o plugin Graph Data Science e carregar o arquivo N-Triples com o script `neo4j/load_graph.py`. O script lê as triplas em blocos, cria ou reutiliza nós e relacionamentos com **MERGE** e, ao final, cria índices sobre **Resource.uri** e **Resource.label**. Como opção mais rápida, o próprio Neo4j Desktop também permite criar uma instância a partir do dump previamente gerado, evitando a reinserção individual das 426.617 relações.


O mesmo dump pode ser utilizado pelo ambiente Docker, que o restaura automaticamente na primeira inicialização. A imagem Enterprise foi utilizada porque o dump está armazenado no formato **block**. O arquivo `compose.yaml` também instala os plugins APOC e Graph Data Science. Como o dump possui aproximadamente 325 MB e excede o limite de tamanho de arquivo do GitHub, ele foi disponibilizado em uma [pasta externa no Google Drive](#), acessível ao professor e aos autores do projeto.

Após a carga, o GDS cria projeções em memória com os tipos e orientações de relacionamentos definidos para cada experimento. Essas projeções não alteram a topologia armazenada no banco. Os escores calculados, entretanto, são gravados na propriedade **pageRank** dos vértices e exportados para arquivos TSV.

Como o Neo4j Browser renderiza no máximo 1.000 nós por padrão [3], não é possível representar simultaneamente os 326.270 vértices do grafo. A Figura 3b apresenta uma amostra global centrada nos 20 vértices de maior grau, limitada a 40 relações incidentes por vértice. A imagem não representa uma componente isolada nem a totalidade da rede; seu objetivo é mostrar a heterogeneidade dos principais hubs e de suas vizinhanças.



(a) Núcleo estrutural com 19 vértices e 60 arestas.



(b) Amostra centrada nos 20 vértices de maior grau.

**Figura 3:** Duas visualizações complementares da rede. Em (a), o núcleo denso usado na análise exploratória, com tamanho proporcional ao grau e cores definidas por Louvain. Em (b), a amostra global do Neo4j Browser, limitada a 40 relações incidentes por vértice e a no máximo 800 relações.

## 5 PageRank

### 5.1 Fundamentação

O PageRank foi proposto originalmente para estimar a importância de páginas da Web a partir da estrutura de hiperlinks [4]. A ideia central é recursiva: um vértice recebe maior pontuação quando é apontado por vértices

que também possuem alta pontuação. Na convenção não normalizada utilizada pelo Neo4j GDS, para um grafo direcionado  $G = (V, E)$ , a recorrência pode ser expressa por:

$$PR^{(i+1)}(v) = (1 - d) + d \sum_{u \in Pred(v)} \frac{PR^{(i)}(u)}{\text{outdeg}(u)}, \quad (1)$$

onde  $Pred(v)$  é o conjunto de predecessores de  $v$ ,  $\text{outdeg}(u)$  é o grau de saída de  $u$  e  $d$  é o fator de amortecimento. O termo  $(1 - d)$  injeta uma pontuação básica em cada vértice a cada iteração. Diferentemente da formulação probabilística que utiliza  $(1 - d)/|V|$ , o GDS retorna por padrão escores brutos não normalizados; essa diferença de escala não altera a ordenação dos vértices [5].

Os experimentos utilizaram a implementação do Neo4j GDS, com fator de amortecimento  $d = 0,85$  e limite de 20 iterações. Esses valores também correspondem aos padrões documentados pela biblioteca [5]. As arestas foram tratadas como não ponderadas e nenhum escalonador foi configurado. Como a análise utiliza a ordem relativa, a ausência de normalização não altera os rankings.

## 5.2 Pseudocódigo

**Listing 1:** Pseudocódigo do PageRank iterativo.

```
função PageRank(Grafo G, real d, inteiro maxIterações):
  para cada vértice v de G:
    PR[v] <- 1

  para iteração <- 1 até maxIterações:
    para cada vértice v de G:
      novoPR[v] <- 1 - d

    para cada vértice u de G:
      se grauSaída(u) > 0:
        parcela <- d * PR[u] / grauSaída(u)
        para cada vizinho de saída v de u:
          novoPR[v] <- novoPR[v] + parcela
      senão:
        u não produz contribuição de saída nesta iteração

  PR <- novoPR

  retornar PR
```

Na execução efetiva, a iteração e o tratamento de vértices sem saída são realizados internamente por `gds.pageRank`. O script `neo4j/pagerank.py` é responsável por criar a projeção apropriada, executar o algoritmo, gravar os escores na propriedade `pageRank` e exportar o ranking para TSV. O pseudocódigo explicita a recorrência dos escores brutos adotada pelo GDS, sem aplicar normalização posterior.

## 5.3 Projeções avaliadas

No fluxo integrado dos experimentos, o conjunto de teste é selecionado e removido antes da execução dos três cenários de PageRank, conforme detalhado na Subseção 8.2. Assim, as projeções são construídas sobre  $G_{treino} = G \setminus E_{teste}$ , que preserva todos os vértices e contém as relações não ocultadas. Neste relatório, *baseline* designa a projeção heterogênea com todos os nove tipos de relacionamento disponíveis em  $G_{treino}$ , e não o grafo original antes da separação entre treino e teste.

O primeiro experimento executou o PageRank sobre esse *baseline*, preservando a orientação natural das relações. Esperava-se encontrar, nas primeiras posições, figuras semelhantes às observadas no núcleo exploratório da Figura 3a, como Immanuel Kant, Leo Strauss e Karl Marx. O ranking obtido, entretanto, foi bastante diferente: além de instituições, religiões e áreas do conhecimento, sua primeira posição geral foi ocupada por Vklush Tolev, figura búlgara associada à religião e à teologia [6], com escore 488,2684.

A investigação desse resultado mostrou que o PageRank não mede diretamente notoriedade histórica ou grau no núcleo visualizado. Ele modela um fluxo de prestígio que percorre as arestas na direção projetada, de modo que tanto o tipo quanto a orientação de uma relação determinam onde a pontuação se acumula. No subgrafo, Tolev recebe arestas `INFLUENCED` de oito tradições religiosas ou mitológicas. Entre elas, *Islam* possui 3.004 arestas de entrada, PageRank 302,2443 e apenas uma aresta de saída; *Christianity* possui 2.617 arestas de entrada, PageRank 223,9322 e também apenas uma saída. Como essas saídas apontam para Tolev, os dois vértices transferem a ele, respectivamente, cerca de 256,91 e 190,34 pontos após a aplicação do fator de

amortecimento. Forma-se, assim, um funil no qual a centralidade acumulada por conceitos religiosos é quase integralmente direcionada a uma única pessoa.

Esse diagnóstico motivou a criação de projeções específicas e o teste da inversão das relações pessoais. Foram definidos três cenários para investigar o efeito da seleção e da orientação das arestas.

**Baseline.** A projeção inclui os nove tipos finais de relacionamento presentes no grafo de treino, em suas orientações naturais. Esse experimento mede centralidade global no grafo heterogêneo remanescente e serve como referência para as demais configurações.

**Pessoas.** A projeção inclui somente `INFLUENCED`, `DOCTORALSTUDENT` e `ACADEMICSTUDENT`, todos com orientação invertida pelo GDS. No arquivo final, essas relações apontam do mentor para o discípulo. Para o PageRank, porém, essa direção transfere pontuação ao discípulo. A inversão faz a caminhada seguir do discípulo para o mentor, permitindo interpretar o escore como prestígio recebido de pessoas influenciadas ou orientadas. No caso de Tolev, as arestas passam a sair dele em direção aos conceitos religiosos, eliminando o funil observado no baseline e aproximando o ranking da interpretação desejada de influência intelectual.

**Institucional.** A projeção inclui `INFLUENCED`, `DOCTORALSTUDENT`, `ACADEMICSTUDENT` e `ALMAMATER` em orientação natural. A relação `ALMAMATER` aponta da pessoa para a instituição; portanto, universidades acumulam prestígio proveniente de seus ex-alunos. As relações pessoais foram mantidas para preservar caminhos de influência e formação antes da transferência para as instituições.

**Tabela 4:** Configuração dos experimentos de PageRank.

| Experimento   | Relações                                                                              | Orientação |
|---------------|---------------------------------------------------------------------------------------|------------|
| Baseline      | Todos os nove tipos finais                                                            | Natural    |
| Pessoas       | <code>INFLUENCED</code> , <code>DOCTORALSTUDENT</code> , <code>ACADEMICSTUDENT</code> | Invertida  |
| Institucional | As três relações anteriores e <code>ALMAMATER</code>                                  | Natural    |

A Figura 4 apresenta os três recortes utilizados para inspecionar visualmente os experimentos. As setas exibem a orientação armazenada no banco; no painel de pessoas, portanto, ainda não está aplicada a inversão realizada somente na projeção em memória do GDS.

## 6 Avaliação do PageRank

### 6.1 Referência para pessoas


O ranking de pessoas foi comparado a uma referência construída a partir da Stanford Encyclopedia of Philosophy (SEP), enciclopédia acadêmica mantida pela Universidade Stanford [7]. Inicialmente, o script `analysis/filter_dbpedia_people.py` consultou o endpoint SPARQL da DBpedia em lotes e manteve apenas recursos classificados como pessoa. As respostas foram armazenadas em cache para permitir a retomada do processo sem repetir consultas. Esse filtro produziu 3.936 candidatos válidos.

A referência externa foi construída pelo script `analysis/build_sep_citation_ranking.py`, responsável pela raspagem automatizada das entradas da SEP. O programa parte da página de conteúdos da enciclopédia, coleta os endereços de todas as páginas sob `/entries/` e baixa seus documentos HTML. Para reduzir tráfego e tornar a execução retomável, cada página é armazenada em um cache local identificado pelo hash da URL; entre novos downloads, aplica-se ainda um intervalo de 0,5 segundo. A análise dos arquivos já armazenados é paralelizada entre os processadores disponíveis.


Antes do casamento dos nomes, o texto HTML é convertido para texto simples, com remoção de elementos de navegação, cabeçalhos, rodapés, scripts e estilos. Tanto o conteúdo quanto os rótulos dos candidatos passam por normalização Unicode, remoção de acentos e uniformização de espaços. O script também remove qualificadores finais de desambiguação, como `“(philosopher)”`, e corrige rótulos com tokens repetidos. Para cada candidato, utiliza-se o nome completo como alias principal; o sobrenome é aceito como alias secundário somente quando é suficientemente longo, não corresponde a uma palavra comum e não aparece em outro candidato. Expressões regulares com limites de palavra evitam correspondências dentro de termos maiores.

Para cada candidato, contou-se em quantas entradas distintas da SEP ao menos um alias aparecia e quantas ocorrências brutas foram encontradas. O primeiro valor foi adotado como escore de referência, pois reduz o peso de repetições dentro de uma mesma página; a contagem bruta serviu como critério secundário de desempate. O arquivo resultante, `analysis/sep_citation_ranking.tsv`, também registra os aliases reconhecidos e até cinco exemplos de páginas correspondentes, permitindo auditar os resultados da raspagem.


Foram empregadas duas métricas. A correlação de Spearman compara a ordem dos candidatos comuns aos dois rankings. Já o `Overlap@k` mede a fração de elementos compartilhados entre os  $k$  primeiros colocados do PageRank e da referência da SEP:



(a) Funil do baseline em torno de Vaklush Tolev.



(b) Relações de influência e orientação em torno de figuras do núcleo estrutural.



(c) Universidades selecionadas e seus ex-alunos de maior grau.

**Figura 4:** Recortes do grafo produzidos no Neo4j Browser para examinar os três cenários de PageRank. Em (a), arestas **RELIGION** alimentam tradições que apontam para Tolev por **INFLUENCED**; em (b), são mostradas as direções originais das relações pessoais; em (c), **ALMAMATER** aponta dos ex-alunos para as instituições.

$$Overlap@k = \frac{|Top_k(PR) \cap Top_k(SEP)|}{k}. \quad (2)$$

O uso de  $Overlap@k$  decorre da natureza simétrica dessa comparação: tanto o PageRank quanto a SEP produzem rankings, e a pergunta é quanto seus respectivos conjuntos  $Top-k$  concordam. A SEP não é tratada como uma lista absoluta de respostas corretas, mas como uma ordenação externa com a qual se deseja medir concordância.

Essa referência não deve ser interpretada como medida absoluta de importância filosófica. A frequência de nomes na SEP depende de cobertura editorial, ambiguidades e do papel desempenhado por certos autores na própria enciclopédia. Ela fornece, contudo, um critério externo reproduzível para comparar as duas projeções do mesmo grafo.

## 6.2 Referência para universidades

As universidades foram identificadas por palavras-chave em seus rótulos, como **university**, **college**, **polytechnic** e equivalentes em outros idiomas. Os resultados foram comparados ao Top 20 do Center for World University Rankings (CWUR) de 2026 [8]. Diferentemente da comparação entre pessoas, o Top 20 do CWUR foi tratado como um conjunto fixo de instituições relevantes. A  $Precision@k$  corresponde, portanto, à proporção das  $k$  universidades mais bem colocadas pelo PageRank que pertencem a esse conjunto de elite:

$$Precision@k = \frac{|Top_k(PR) \cap Elite_{CWUR}|}{k}. \quad (3)$$

Essa métrica responde quantas das instituições recomendadas pelo algoritmo são consideradas relevantes pela referência. Por exemplo,  $Precision@10$  igual a 100% significa que todas as dez primeiras universidades do PageRank pertencem ao Top 20 do CWUR; não significa que as vinte instituições da referência tenham sido recuperadas. A correlação de Spearman foi calculada separadamente entre as posições das universidades do CWUR encontradas no grafo.

O CWUR avalia universidades por critérios diferentes da centralidade desta rede e, por isso, funciona como referência aproximada, não como verdade fundamental. A comparação verifica se as relações de formação e influência recuperam instituições reconhecidas externamente.

## 7 Resultados e discussão do PageRank

### 7.1 Pessoas e intelectuais

A projeção reversa para pessoas apresentou resultados superiores ao baseline em todas as métricas. A correlação de Spearman aumentou de 0,230920 para 0,499841. O  $Overlap@20$  passou de 0% para 35%, e o  $Overlap@50$  passou de 4% para 40%.

**Tabela 5:** PageRank de pessoas comparado à referência da SEP.

| Projeção                     | Spearman        | Overlap@20 | Overlap@50 |
|------------------------------|-----------------|------------|------------|
| Baseline                     | 0,230920        | 0%         | 4%         |
| Pessoas, relações invertidas | <b>0,499841</b> | <b>35%</b> | <b>40%</b> |

O ganho confirma que a orientação semântica das arestas é decisiva. No baseline, relações heterogêneas fazem a pontuação fluir para instituições, religiões, áreas e obras. Na projeção de pessoas, a remoção dessas relações reduz a competição com entidades que não são indivíduos, enquanto a inversão direciona prestígio de discípulos para mentores. Kant, Aristóteles e Platão passam a ocupar as primeiras posições, em maior concordância com a referência externa.

A correlação permanece abaixo de uma concordância perfeita. Isso é esperado porque os critérios não são equivalentes: o PageRank mede posição estrutural nas relações registradas pela DBpedia, enquanto a referência mede presença textual nas entradas da SEP. O aparecimento de Ferdinand von Lindemann entre os dez primeiros, por exemplo, indica que cadeias acadêmicas muito documentadas podem elevar candidatos cuja presença na tradição filosófica é mais restrita. Esse caso evidencia tanto a informação capturada pelo grafo quanto o viés de cobertura de suas relações.

**Tabela 6:** Dez primeiros candidatos válidos na projeção de pessoas.

| Posição | Pessoa                    | Escore  |
|---------|---------------------------|---------|
| 1       | Immanuel Kant             | 58,0966 |
| 2       | Aristotle                 | 50,1809 |
| 3       | Plato                     | 40,7841 |
| 4       | Gottfried Wilhelm Leibniz | 27,3950 |
| 5       | Pythagoras                | 27,2734 |
| 6       | Ferdinand von Lindemann   | 25,6811 |
| 7       | Parmenides                | 23,4694 |
| 8       | Heraclitus                | 23,0318 |
| 9       | Bertrand Russell          | 20,3374 |
| 10      | David Hume                | 19,7355 |

## 7.2 Universidades

Para universidades, o baseline obteve Precision@10 de 100%, enquanto a projeção institucional atingiu 90%. Ambas alcançaram Precision@20 de 65%. A correlação com a ordem do CWUR também foi ligeiramente maior no baseline: 0,545865 contra 0,526316.

**Tabela 7:** PageRank de universidades comparado ao CWUR 2026.

| Projeção      | Precision@10 | Precision@20 | Spearman        |
|---------------|--------------|--------------|-----------------|
| Baseline      | <b>100%</b>  | 65%          | <b>0,545865</b> |
| Institucional | 90%          | 65%          | 0,526316        |

**Tabela 8:** Dez primeiras universidades na projeção institucional.

| Posição | Universidade                       | Escore   |
|---------|------------------------------------|----------|
| 1       | Harvard University                 | 318,0176 |
| 2       | University of Michigan             | 288,3303 |
| 3       | Princeton University               | 244,0913 |
| 4       | Yale University                    | 220,1037 |
| 5       | Columbia University                | 189,7218 |
| 6       | University of Chicago              | 146,7403 |
| 7       | University of Cambridge            | 141,6175 |
| 8       | University of California, Berkeley | 138,6354 |
| 9       | Stanford University                | 135,5410 |
| 10      | Hebrew University of Jerusalem     | 129,1625 |

A projeção institucional concentrou as primeiras posições em universidades reconhecidas, demonstrando que **ALMAMATER** oferece um sinal relevante de prestígio. Entretanto, ela não superou o baseline segundo as métricas adotadas. Isso sugere que as demais relações da projeção heterogênea de treino também carregam informação útil para instituições ou que a composição institucional escolhida ainda preserva ruído suficiente para alterar as primeiras posições.

Os resultados mostram que uma projeção especializada não é automaticamente superior. No caso de pessoas, a direção original contrariava o fluxo de prestígio desejado e sua inversão produziu ganho expressivo. No caso institucional, **ALMAMATER** já possuía a direção adequada, e a restrição do conjunto de relações não trouxe melhora mensurável. A seleção das arestas deve, portanto, ser fundamentada na semântica de cada relação e validada empiricamente.

## 8 Personalized PageRank e predição de ligações

### 8.1 Motivação e formulação

O Personalized PageRank (PPR) modifica o mecanismo de teletransporte do PageRank. Em vez de reiniciar a caminhada aleatória uniformemente em qualquer vértice, concentra-se a probabilidade de reinício em um vértice fonte  $s$ . Seja  $P$  a matriz de transição do grafo,  $\mathbf{e}_s$  o vetor que vale 1 em  $s$  e 0 nos demais vértices e  $d$  o fator de amortecimento. O vetor personalizado é obtido iterativamente por

$$\pi_s^{(i+1)} = (1 - d)\mathbf{e}_s + dP^\top \pi_s^{(i)}. \quad (4)$$

Valores elevados de  $\pi_s(t)$  indicam que  $t$  é estruturalmente alcançável e relevante a partir de  $s$ . O PPR não avalia diretamente o significado textual das entidades: ele mede proximidade topológica condicionada à orientação e aos tipos de aresta. Por essa razão, a comparação com similaridade lexical da WordNet, prevista na proposta inicial, foi substituída por uma avaliação de predição de ligações. Esse protocolo testa diretamente se a estrutura conhecida é capaz de recuperar relações reais deliberadamente ocultadas.

### 8.2 Construção dos conjuntos de treino e teste

O script `neo4j/split_edges.py` parte das 426.617 arestas e calcula iterativamente o núcleo de ordem 5 do grafo não direcionado subjacente. Permanecem nesse núcleo 2.698 vértices e 14.233 arestas. O filtro é usado apenas para definir quais arestas podem ser ocultadas; as regiões periféricas continuam disponíveis no grafo de treino.

Com semente pseudoaleatória 42, selecionam-se 10% das arestas elegíveis, resultando em 1.423 casos de teste. Uma aresta  $(s, r, t)$  só pode ser removida se, após sua retirada, a origem mantiver ao menos duas saídas, o destino mantiver ao menos uma entrada e ambos preservarem grau total mínimo 3 dentro do núcleo. Essas restrições evitam casos triviais em que a própria ocultação isola os vértices avaliados.

As arestas escolhidas são registradas em `neo4j/test_edges.tsv`, marcadas temporariamente no banco e então removidas fisicamente. O grafo restante constitui  $G_{\text{treino}}$  e o TSV funciona como gabarito  $E_{\text{teste}}$ . Como as ligações avaliadas não participam das projeções do GDS, o algoritmo não pode utilizar a resposta durante o cálculo, prevenindo vazamento de dados.

### 8.3 Execução do PPR

O script `neo4j/ppr.py` agrupa as arestas de teste por tipo de relação. Para cada tipo  $r$ , cria-se uma projeção GDS contendo somente relações desse tipo em orientação natural. Em seguida, para cada origem distinta  $s$  presente no gabarito, executa-se `gds.pageRank.stream` com  $s$  como `sourceNode`, fator de amortecimento 0,85, limite de 20 iterações e retenção dos 500 destinos de maior score, excluindo a própria origem. As fontes são processadas em lotes de 50 e cada projeção é descartada após o término do respectivo tipo, reduzindo o consumo de memória.

Para uma aresta oculta  $(s, r, t)$ , o ranking produzido a partir de  $(s, r)$  é interpretado como uma lista de destinos candidatos. A predição é considerada recuperada quando  $t$  aparece nessa lista. A avaliação é não filtrada: o script exclui a própria origem, mas não remove da lista os destinos que já possuem uma ligação observada do tipo  $r$  com  $s$  em  $G_{\text{treino}}$ . Essas ligações conhecidas podem ocupar posições no Top- $K$ , tornando a avaliação mais conservadora, mas não provocam vazamento da aresta de teste, que foi removida antes da projeção. O procedimento completo é sintetizado no pseudocódigo a seguir.

**Listing 2:** Pseudocódigo da avaliação do PPR por predição de ligações.

```
função AvaliarPPR(G, k=5, proporçãoTeste=0.10, K=500):
  C <- k-core de ordem k do grafo subjacente de G
  E_teste <- selecionar arestas de C preservando graus mínimos
  G_treino <- G sem E_teste

  para cada tipo de relação r presente em E_teste:
    G_r <- projetar em G_treino somente as relações do tipo r

    para cada origem distinta s das arestas (s, r, t):
      ranking[s, r] <- Top-K do PPR(G_r, fonte=s)

    descartar G_r

  para cada aresta (s, r, t) em E_teste:
    rank[s, r, t] <- posição de t em ranking[s, r]
```

retornar HitRate@K, MRR e recuperação no Top-500

## 8.4 Métricas

O HitRate@ $k$  mede a proporção de arestas ocultas cujo destino verdadeiro aparece entre os  $k$  primeiros candidatos. Para cada caso há um destino de teste específico; por isso, HitRate é mais apropriado que Precision, que dividiria o número de itens relevantes recuperados pelo total de  $k$  recomendações:

$$\text{HitRate}@k = \frac{1}{|E_{teste}|} \sum_{(s,r,t) \in E_{teste}} \mathbb{I}[t \in \text{Top}_k(s, r)]. \quad (5)$$

O Mean Reciprocal Rank (MRR) considera também a posição do destino correto. Acertos nas primeiras posições recebem maior peso, enquanto arestas não recuperadas contribuem com zero:

$$\text{MRR} = \frac{1}{|E_{teste}|} \sum_{(s,r,t) \in E_{teste}} \begin{cases} 1/\text{rank}_{s,r}(t), & \text{se } t \text{ foi recuperado;} \\ 0, & \text{caso contrário.} \end{cases} \quad (6)$$

O código denomina *coverage* a fração de arestas encontradas no Top-500. No relatório, essa medida é chamada de taxa de recuperação no Top-500 para distingui-la da noção tradicional de cobertura de usuários ou itens em sistemas de recomendação.

## 8.5 Resultados e interpretação

As métricas foram recalculadas diretamente a partir das 1.423 linhas do artefato final `neo4j/ppr_predictions.tsv`. O PPR recuperou 439 destinos no Top-500, equivalentes a 30,85% do conjunto de teste. Entretanto, apenas 4,22% das arestas apareceram nas vinte primeiras posições, e o MRR foi 0,011418. A Tabela 9 resume os resultados.

**Tabela 9:** Resultados do PPR na tarefa de predição de ligações.

| Métrica          | Valor    | Métrica                | Valor        |
|------------------|----------|------------------------|--------------|
| Arestas de teste | 1.423    | Recuperadas no Top-500 | 439 (30,85%) |
| HitRate@1        | 0,002811 | HitRate@5              | 0,011947     |
| HitRate@10       | 0,021082 | HitRate@20             | 0,042164     |
| MRR              | 0,011418 |                        |              |

O desempenho varia fortemente entre os tipos de relacionamento. Das 736 arestas **INFLUENCED** avaliadas, 436 foram encontradas no Top-500, uma taxa de 59,24%. Para **IDEOLOGY**, houve 3 acertos em 462 casos; nos demais 225 casos, distribuídos entre **RELIGION**, **ALMAMATER**, **FIELD**, **DOCTORALSTUDENT**, **ACADEMICSTUDENT** e **KNOWNFOR**, não houve recuperação.

Essa diferença é explicada pela topologia das projeções. **INFLUENCED** forma cadeias direcionadas nas quais pessoas podem atuar simultaneamente como origem e destino, oferecendo caminhos alternativos até uma ligação oculta. Relações como **ALMAMATER**, **RELIGION** e **FIELD** são predominantemente bipartidas: pessoas apontam para instituições, religiões ou áreas que raramente possuem saídas do mesmo tipo. Quando a aresta direta é removida, o destino tende a se tornar inalcançável naquela projeção. Assim, a taxa global de 30,85% é concentrada quase inteiramente na rede de influência.

Os valores baixos de HitRate nos primeiros cortes e de MRR mostram ainda que muitos dos destinos recuperados aparecem longe do topo. O experimento confirma que o PPR captura proximidade estrutural quando existem caminhos direcionados alternativos, mas não substitui informação semântica ausente. Projeções não direcionadas, combinações de diferentes tipos de relação ou pesos específicos poderiam ampliar a conectividade, porém constituiriam hipóteses distintas e exigiriam nova validação para evitar que o ganho decorresse apenas da introdução artificial de caminhos.

## 9 Uso de inteligência artificial generativa

Ferramentas de IA generativa foram utilizadas como apoio à análise exploratória, à programação, à infraestrutura e à redação técnica. Nos estágios iniciais, elas auxiliaram a inspecionar o dump da DBpedia, que contém milhões de triplas, e a identificar predicados e padrões compatíveis com o recorte intelectual proposto. Também

apoiaram a elaboração e a revisão dos scripts de filtragem, cálculo de métricas, raspagem da SEP, consultas Cypher e automação do ambiente com Docker Compose.

O Antigravity foi empregado principalmente como copiloto de infraestrutura. A ferramenta auxiliou no diagnóstico de conflitos entre o Neo4j Desktop e o Docker, incluindo portas ocupadas, volumes bloqueados, permissões de arquivos e problemas de DNS e IPv6 na JVM. Também apoiou a identificação da incompatibilidade entre o formato `block` do dump e a edição Community, a migração da composição para Neo4j Enterprise e a criação do `load_dump.sh`, responsável por restaurar automaticamente o banco sem sobrescrever volumes já inicializados.

O Codex, da OpenAI, foi utilizado para inspecionar o repositório e cruzar documentação, código e artefatos; formalizar as métricas e os pseudocódigos; revisar a interpretação dos experimentos; elaborar consultas Cypher para as visualizações; estruturar o relatório em LaTeX e verificar sua compilação e paginação. A ferramenta também auxiliou na conferência entre a implementação, os resultados obtidos e sua apresentação no texto final.

Todas as sugestões foram avaliadas pelos autores. A definição do problema, a escolha dos dados e experimentos, a execução dos programas, a inspeção dos resultados e a decisão de aceitar, modificar ou rejeitar cada proposta permaneceram sob responsabilidade de Raphael Salles Vitor de Souza e Lucas Félix. Os valores apresentados no relatório foram produzidos pelos scripts e artefatos do projeto, e não estimados pelos modelos generativos.

## 10 Conclusão

Este trabalho transformou um dump de 22,8 milhões de triplas da DBpedia em uma rede intelectual direcionada, reproduzível e adequada à análise em Neo4j. A seleção e a normalização de 11 predicados resultaram em 326.270 vértices e 426.617 arestas. A rede apresentou forte heterogeneidade de graus e elevada fragmentação dirigida: 99,97% das componentes fortemente conexas são unitárias. Essas propriedades não são apenas descritivas, pois condicionam diretamente o funcionamento dos algoritmos de caminhada aleatória.

Desde a concepção do projeto, o objetivo central foi investigar se relações extraídas da Wikipédia, uma fonte ampla e colaborativa, seriam suficientes para recuperar padrões compatíveis com referências externas mais curadas. Os rankings não receberam informações da SEP ou do CWUR durante seu cálculo: eles foram produzidos exclusivamente pela topologia da DBpedia e somente depois confrontados com essas referências. Para pessoas, construiu-se a partir da SEP uma ordenação por presença em entradas de uma enciclopédia acadêmica; para universidades, utilizou-se o Top 20 do CWUR. O cruzamento permitiu avaliar se o reconhecimento registrado por fontes independentes também emergia da estrutura das relações da Wikipédia. Essas referências não foram tratadas como verdades absolutas, pois também possuem critérios e vieses próprios, mas como parâmetros externos mais controlados do que o conjunto heterogêneo usado para construir o grafo.

Os resultados mostraram uma concordância parcial e sensível à modelagem. A projeção invertida de pessoas elevou a correlação de Spearman com a SEP de 0,230920 para 0,499841 e o `Overlap@50` de 4% para 40%, indicando que a rede contém sinal compatível com o reconhecimento externo quando o fluxo é orientado de acordo com a interpretação de influência. Já a projeção institucional não superou o baseline, demonstrando que restringir relações não garante melhoria automática. O caso de Vaklush Tolev evidenciou como hubs religiosos e direções inadequadas podem criar funis de prestígio que não correspondem à expectativa histórica.

Na predição de ligações, o PPR recuperou 30,85% das arestas ocultas no Top-500, mas obteve `HitRate@20` de apenas 4,22% e `MRR` de 0,011418. Quase todos os acertos vieram de `INFLUENCED`, cuja topologia oferece caminhos alternativos; relações bipartidas, como `ALMAMATER` e `RELIGION`, tornaram seus destinos inalcançáveis após a ocultação da ligação direta. Conclui-se que dados derivados da Wikipédia podem revelar padrões de influência corroborados parcialmente por referências curadas, mas proximidade estrutural, notoriedade histórica e proximidade semântica não são equivalentes. Trabalhos futuros podem combinar topologia e informação textual, investigar projeções heterogêneas ponderadas e empregar validações temporais, sempre preservando um protocolo sem vazamento de dados.

## A Consultas Cypher das visualizações

As consultas a seguir foram executadas no Neo4j Browser para produzir os SVGs das Figuras 3b e 4. Os limites fazem parte do protocolo de visualização e evitam ultrapassar a capacidade de renderização da ferramenta. O arquivo executável completo está disponível em `docs/latex/neo4j_visualizations.cypher`.

**Listing 3:** Consulta da amostra global representativa.

```

1 // =====
2 // 1. VISÃO GLOBAL REPRESENTATIVA
3 // =====
4 // Seleciona os 20 vértices de maior grau e até 40 relações incidentes
5 // por vértice. O resultado tem no máximo 800 relações e permanece
6 // abaixo do limite visual padrão de 1.000 nós do Neo4j Browser.
7
8 MATCH (n:Resource)-[incident]-()
9 WITH n, count(incident) AS degree
10 ORDER BY degree DESC
11 LIMIT 20
12 CALL {
13     WITH n
14     MATCH (n)-[r]-(m:Resource)
15     WITH r, m
16     ORDER BY m.label
17     LIMIT 40
18     RETURN r, m
19 }
20 RETURN n, r, m;
```

**Listing 4:** Consulta do funil do baseline em torno de Vaklush Tolev.

```

1 // =====
2 // 2. FUNIL DO BASELINE: VAKLUSH TOLEV
3 // =====
4 // Mostra as tradições que apontam para Tolev e até 25 recursos que
5 // alimentam cada tradição pela relação RELIGION. As setas preservam
6 // a orientação armazenada no banco.
7
8 MATCH p=(tradition:Resource)-[:INFLUENCED]->
9     (tolev:Resource {label: 'Vaklush Tolev'})
10 CALL {
11     WITH tradition
12     OPTIONAL MATCH q=(person:Resource)-[:RELIGION]->(tradition)
13     WITH q, person
14     ORDER BY person.label
15     LIMIT 25
16     RETURN q
17 }
18 RETURN p, q;
```

**Listing 5:** Consulta do segmento de pessoas.

```

1 // =====
2 // 3. SEGMENTO DE PESSOAS: INFLUÊNCIA E ORIENTAÇÃO
3 // =====
4 // Recorte de um salto ao redor de figuras presentes no núcleo da
5 // Figura 3. A visualização exibe a direção original das relações;
6 // a projeção GDS usada no experimento de pessoas é que as inverte.
7
8 MATCH p=(a:Resource)-[r]-(b:Resource)
9 WHERE type(r) IN ['INFLUENCED', 'DOCTORALSTUDENT', 'ACADEMICSTUDENT']
10 AND (
11     a.label IN [
12         'Immanuel Kant', 'Plato', 'Aristotle', 'David Hume',
13         'Leo Strauss', 'Karl Marx', 'Bertrand Russell',
14         'Friedrich Nietzsche'
15     ]
16     OR
17     b.label IN [
18         'Immanuel Kant', 'Plato', 'Aristotle', 'David Hume',
19         'Leo Strauss', 'Karl Marx', 'Bertrand Russell',
20         'Friedrich Nietzsche'
21     ]
22 )
23 RETURN DISTINCT p
24 LIMIT 500;
```

**Listing 6:** Consulta do segmento institucional.

```

1 // =====
2 // 4. SEGMENTO INSTITUCIONAL: UNIVERSIDADES E EX-ALUNOS
3 // =====
4 // Para cada universidade, seleciona até 25 ex-alunos com maior grau
5 // no grafo completo. O resultado tem no máximo 250 relações.
6
7 UNWIND [
8     'Harvard University',
9     'University of Michigan',
10    'Princeton University',
11    'Yale University',
12    'Columbia University',
13    'University of Chicago',
14    'University of Cambridge',
15    'University of California, Berkeley',
16    'Stanford University',
17    'Massachusetts Institute of Technology'
18 ] AS universityName
19 MATCH (uni:Resource {label: universityName})
20 CALL {
21     WITH uni
22     MATCH p=(person:Resource)-[:ALUMNUS]->(uni)
23     MATCH (person)-[incident]-()
24     WITH p, count(incident) AS personDegree
25     ORDER BY personDegree DESC
26     LIMIT 25
27     RETURN p
28 }
29 RETURN p;
```

## Referências

- [1] DBpedia Association. *About DBpedia*. URL: <https://www.dbpedia.org/about/> (acesso em 22/06/2026).
- [2] DBpedia Association. *Mapping-based Objects: English, snapshot 2022-12-01*. 2022. URL: [https://databus.dbpedia.org/dbpedia/mappings/mappingbased-objects/2022.12.01/mappingbased-objects\\_lang=en.ttl.bz2](https://databus.dbpedia.org/dbpedia/mappings/mappingbased-objects/2022.12.01/mappingbased-objects_lang=en.ttl.bz2) (acesso em 22/06/2026).
- [3] Neo4j. *Neo4j Browser Settings*. URL: <https://neo4j.com/docs/browser/operations/browser-settings/> (acesso em 22/06/2026).
- [4] Lawrence Page et al. “The PageRank Citation Ranking: Bringing Order to the Web”. Em: *The Web Conference*. 1999. URL: <https://www.semanticscholar.org/paper/The-PageRank-Citation-Ranking-%3A-Bringing-Order-to-Page-Brin/eb82d3035849cd23578096462ba419b53198a556> (acesso em 21/06/2026).
- [5] Neo4j. *PageRank — Neo4j Graph Data Science*. URL: <https://neo4j.com/docs/graph-data-science/current/algorithms/page-rank/> (acesso em 22/06/2026).
- [6] DBpedia Association. *About: Vaklush Tolev*. URL: [https://dbpedia.org/page/Vaklush\\_Tolev](https://dbpedia.org/page/Vaklush_Tolev) (acesso em 22/06/2026).
- [7] Stanford University. *Stanford Encyclopedia of Philosophy*. URL: <https://plato.stanford.edu/> (acesso em 22/06/2026).
- [8] Center for World University Rankings. *World University Rankings 2026*. 2026. URL: <https://cwur.org/2026.php> (acesso em 22/06/2026).