

Rede Intelectual da DBpedia

Aplicação de PageRank e análise estrutural em um grafo de conhecimento

Raphael Salles Vitor de Souza (RA 223641)

Lucas Félix (RA 247064)

MC859 — Projeto em Teoria da Computação

Prof. Ruben Interian Kovaliova — Universidade Estadual de Campinas

22 de junho de 2026

Implementação pública:

<https://github.com/RaphaelSVSouza/mc859-dbpedia-intellectual-network>

1 Introdução

Grafos de conhecimento representam entidades como vértices e relações semânticas como arestas. Essa estrutura permite estudar não apenas os atributos isolados de uma entidade, mas também sua posição em uma rede de relações. A DBpedia é especialmente adequada a esse tipo de análise porque extrai informação estruturada da Wikipédia e a disponibiliza como dados ligados, reunindo entidades de diferentes domínios em uma base de conhecimento aberta [1].

Este trabalho construiu uma rede intelectual a partir da DBpedia, concentrando-se em relações de influência, orientação acadêmica, formação, áreas de atuação, obras, religião e ideologia. A hipótese investigada é que a estrutura dessas relações contém sinais capazes de distinguir entidades relevantes e de recuperar parte da organização semântica presente no domínio. Em vez de considerar toda a DBpedia, foi produzido um subgrafo temático direcionado, adequado à execução de algoritmos de centralidade em hardware acadêmico convencional.

A análise foi dividida em três partes. Primeiro, estudaram-se propriedades estruturais do grafo, como distribuição de graus e componentes fortemente conexas. Em seguida, aplicou-se PageRank para produzir rankings globais em três projeções distintas: o grafo completo, uma projeção voltada a pessoas e uma projeção institucional. Por fim, o Personalized PageRank foi empregado em um experimento de predição de arestas. Esta última etapa será apresentada na continuação do relatório.

1.1 Objetivo geral

Construir e analisar um grafo de conhecimento direcionado, derivado da DBpedia, para investigar em que medida sua topologia permite identificar entidades intelectualmente relevantes e recuperar relações ocultas do grafo.

1.2 Objetivos específicos

- extrair do dump da DBpedia um subconjunto de relações associadas à rede intelectual;
- normalizar a orientação semântica de relações inversas e eliminar triplas duplicadas;
- serializar o grafo nos formatos N-Triples, GEXF e GraphML;
- instanciar o grafo no Neo4j e projetá-lo com o Graph Data Science;
- caracterizar sua estrutura por métricas de grau e conectividade;
- comparar variantes do PageRank voltadas a pessoas e instituições;
- avaliar os rankings obtidos por meio de referências externas;
- avaliar o Personalized PageRank como método de predição de ligações.

2 Aquisição e preparação dos dados

2.1 Fonte dos dados

A coleta utilizou o arquivo `mappingbased-objects_lang=en.ttl.bz2`, correspondente ao componente *mapping-based objects* em inglês da DBpedia, no snapshot de 1º de dezembro de 2022 [2]. Esse dump contém triplas RDF extraídas principalmente das infocaixas da Wikipédia. Cada registro segue a forma $\langle s, p, o \rangle$, na qual s é o recurso de origem, p é o predicado e o é outro recurso identificado por URI.

O dump utilizado continha 22.791.171 triplas. Como o objetivo não era reproduzir toda a DBpedia, foram selecionados 11 predicados relacionados à circulação de influência e à caracterização intelectual: `influencedBy`,

influenced, doctoralAdvisor, doctoralStudent, academicAdvisor, almaMater, knownFor, notableWork, field, religion e ideology.

A filtragem foi feita por correspondência literal com `grep -F`, utilizando a lista versionada em `pipeline/preds.txt`. Esse procedimento reduziu o conjunto para 432.975 triplas.

2.2 Reorientação das relações

Predicados inversos podem representar a mesma relação com direções opostas. Para estabelecer uma convenção única, três relações foram reescritas:

$$\begin{aligned}\text{influencedBy}(A, B) &\longrightarrow \text{influenced}(B, A), \\ \text{doctoralAdvisor}(A, B) &\longrightarrow \text{doctoralStudent}(B, A), \\ \text{academicAdvisor}(A, B) &\longrightarrow \text{academicStudent}(B, A).\end{aligned}$$

Assim, as arestas de influência e orientação passaram a apontar do influenciador ou orientador para a pessoa influenciada ou orientada. A transformação foi implementada com `awk`, trocando sujeito e objeto quando o predicado pertencia ao conjunto de relações inversas.

Como a DBpedia pode registrar simultaneamente uma relação direta e sua inversa, a reorientação gera triplas coincidentes. Um `sort -u` foi então utilizado para deduplicar o resultado. Foram removidas 6.358 ocorrências redundantes, equivalentes a aproximadamente 1,47% das triplas filtradas. Embora tenham sido selecionados 11 predicados na entrada, a normalização produziu nove tipos finais de relação, pois os predicados inversos foram incorporados aos seus equivalentes canônicos.

Tabela 1: Quantidade de triplas nas etapas de preparação.

Etapa	Operação	Triplas
0	Dump <i>mapping-based objects</i> em inglês	22.791.171
1	Filtragem pelos 11 predicados	432.975
2	Reorientação das relações inversas	432.975
3	Deduplicação	426.617

2.3 Composição do grafo final

O grafo final contém 326.270 vértices e 426.617 arestas direcionadas. A Tabela 2 mostra a participação de cada tipo de relação. `almaMater` representa mais da metade das arestas, enquanto `knownFor` responde por 19,00%. Essa assimetria é importante para interpretar os rankings: no grafo completo, instituições de ensino e objetos associados a relações muito frequentes recebem uma parcela considerável do fluxo de prestígio.

Tabela 2: Distribuição das arestas por predicado após a normalização.

Predicado final	Arestas	Participação
<code>almaMater</code>	220.232	51,62%
<code>knownFor</code>	81.055	19,00%
<code>religion</code>	30.421	7,13%
<code>ideology</code>	27.521	6,45%
<code>influenced</code>	22.936	5,38%
<code>doctoralStudent</code>	16.237	3,81%
<code>field</code>	13.586	3,18%
<code>notableWork</code>	11.933	2,80%
<code>academicStudent</code>	2.696	0,63%

2.4 Serialização e reprodutibilidade

O resultado deduplicado foi salvo em N-Triples e convertido para GEXF pelo script `pipeline/nt_to_gexf.py`. Durante a conversão, cada URI recebeu um identificador numérico, os nomes legíveis foram derivados

do trecho final das URIs e os predicados foram armazenados como rótulos das arestas. O wrapper `pipeline/run_pipeline.py` também permite gerar GraphML por meio da biblioteca NetworkX.

O repositório contém os comandos de filtragem, os scripts de conversão e os programas de análise. Dessa forma, o grafo pode ser regenerado de maneira determinística a partir do snapshot indicado da DBpedia. Os arquivos de maior volume também foram disponibilizados separadamente para evitar que a reprodução dependa da etapa mais demorada de processamento do dump original.

3 Estrutura da rede intelectual

A caracterização inicial foi realizada com o script `analysis/analise_graph.py`, que lê o GEXF como um grafo direcionado e calcula graus de entrada e saída e componentes fortemente conexas. As métricas resultantes são apresentadas na Tabela 3.

Tabela 3: Métricas estruturais do grafo.

Métrica	Valor
Vértices	326.270
Arestas direcionadas	426.617
Grau médio total	2,6151
Grau médio de entrada	1,3076
Grau médio de saída	1,3076
Maior grau de entrada	4.068
Maior grau de saída	237
Componentes fortemente conexas	325.240
Maior componente fortemente conexa	840 vértices
Componentes unitárias	325.127 (99,97%)

3.1 Distribuição dos graus

A distribuição observada apresenta uma cauda pesada: a maior parte dos vértices tem poucas conexões, enquanto um conjunto reduzido funciona como *hub*. O maior grau de entrada é 4.068, muito superior ao grau médio total de 2,6151. Entre os vértices de alto grau de entrada aparecem instituições, religiões e áreas do conhecimento, resultado compatível com a frequência de relações como `almaMater`, `religion` e `knownFor`.

Essa heterogeneidade sugere uma estrutura favorável à diferenciação por centralidade. Entretanto, a aparência aproximadamente linear do gráfico em escala log-log não é suficiente, isoladamente, para demonstrar que a distribuição segue uma lei de potência; uma conclusão desse tipo exigiria ajuste e teste estatístico específicos. Neste trabalho, a figura é utilizada apenas como evidência descritiva da concentração de conexões.

3.2 Componentes fortemente conexas

Uma componente fortemente conexa é um conjunto de vértices no qual cada vértice pode alcançar todos os demais respeitando a orientação das arestas. O grafo contém 325.240 componentes desse tipo, das quais 325.127 são unitárias. A maior componente possui 840 vértices.

A fragmentação é coerente com a semântica temporal e hierárquica de parte das relações. Arestas de orientação e influência tendem a seguir do orientador para o aluno ou de uma figura anterior para uma posterior, enquanto `almaMater` liga pessoas a instituições. Essas direções raramente formam caminhos de retorno, produzindo uma rede predominantemente acíclica. A consequência metodológica é relevante: algoritmos baseados em caminhadas aleatórias, principalmente quando executados em projeções restritas, podem alcançar somente uma parcela limitada do grafo a partir de determinada origem.

3.3 Visualização do núcleo estrutural

Para produzir uma visualização legível, foi extraído um subgrafo em três etapas: seleção dos 500 vértices de maior grau no grafo completo, remoção dos vértices com grau inferior a 2 dentro desse subconjunto e escolha da maior componente fracamente conexa remanescente. O resultado contém 19 vértices e 60 arestas. A redução não foi utilizada no cálculo dos rankings; sua finalidade foi exclusivamente exploratória e visual.




Figura 1: Distribuição do grau total em escala log-log. A maior parte dos vértices apresenta grau baixo, enquanto poucos hubs concentram grande número de relações.




Figura 2: Distribuição dos tamanhos das componentes fortemente conexas. Observa-se predominância de componentes unitárias e uma maior componente com 840 vértices.




Figura 3: Núcleo estrutural obtido a partir dos vértices de maior grau. O tamanho dos vértices é proporcional ao grau total e as cores representam comunidades identificadas por Louvain.

4 Instanciação no Neo4j

O grafo foi instanciado no Neo4j seguindo o modelo de grafo de propriedades. Cada recurso RDF foi representado por um nó com o rótulo **Resource** e duas propriedades principais: **uri**, que preserva seu identificador original, e **label**, que armazena uma forma legível do nome. Cada predicado foi convertido em um tipo de relacionamento em letras maiúsculas. Por exemplo,

```
<http://dbpedia.org/resource/Albert_Einstein>
<http://dbpedia.org/ontology/influenced>
<http://dbpedia.org/resource/Niels_Bohr> .
```

é representado como:

```
(Albert Einstein)-[:INFLUENCED]->(Niels Bohr)
```

O banco pode ser preparado de duas maneiras. Na primeira, utiliza-se o Neo4j Desktop: é possível criar uma instância vazia, instalar o plugin Graph Data Science e carregar o arquivo N-Triples com o script `neo4j/load_graph.py`. O script lê as triplas em blocos, cria ou reutiliza nós e relacionamentos com **MERGE** e, ao final, cria índices sobre **Resource.uri** e **Resource.label**. Como opção mais rápida, o próprio Neo4j Desktop também permite criar uma instância a partir do dump previamente gerado, evitando a reinserção individual das 426.617 relações.

O mesmo dump pode ser utilizado pelo ambiente Docker, que o restaura automaticamente na primeira inicialização. A imagem Enterprise foi utilizada porque o dump está armazenado no formato **block**. O arquivo `compose.yaml` também instala os plugins APOC e Graph Data Science. Como o dump possui aproximadamente 325 MB e excede o limite de tamanho de arquivo do GitHub, ele foi disponibilizado em uma [pasta externa no Google Drive](#), acessível ao professor e aos autores do projeto.

Após a carga, o GDS cria projeções em memória com os tipos e orientações de relacionamentos definidos para cada experimento. Essas projeções não alteram a topologia armazenada no banco. Os escores calculados, entretanto, são gravados na propriedade **pageRank** dos vértices e exportados para arquivos TSV.

5 PageRank

5.1 Fundamentação

O PageRank foi proposto originalmente para estimar a importância de páginas da Web a partir da estrutura de hiperlinks [3]. A ideia central é recursiva: um vértice recebe maior pontuação quando é apontado por vértices

que também possuem alta pontuação. Em um grafo direcionado $G = (V, E)$, a atualização utilizada pode ser expressa por:

$$PR(v) = \frac{1-d}{|V|} + d \sum_{u \in Pred(v)} \frac{PR(u)}{\text{outdeg}(u)}, \quad (1)$$

onde $Pred(v)$ é o conjunto de predecessores de v , $\text{outdeg}(u)$ é o grau de saída de u e d é o fator de amortecimento. O termo de teletransporte representa a possibilidade de abandonar a caminhada atual e reiniciá-la em outro vértice, reduzindo o efeito de sumidouros e ciclos fechados.

Os experimentos utilizaram a implementação do Neo4j GDS, com fator de amortecimento $d = 0,85$ e limite de 20 iterações. Esses valores também correspondem aos padrões documentados pela biblioteca [4]. As arestas foram tratadas como não ponderadas. O GDS produz escores que não precisam somar 1; como a análise utiliza a ordem relativa, essa escala não altera os rankings.

5.2 Pseudocódigo

Listing 1: Pseudocódigo do PageRank iterativo.

```
função PageRank(Grafo G, real d, inteiro maxIterações):
    N <- quantidade de vértices de G

    para cada vértice v de G:
        PR[v] <- 1 / N

    para iteração <- 1 até maxIterações:
        para cada vértice v de G:
            novoPR[v] <- (1 - d) / N

        para cada vértice u de G:
            se grauSaída(u) > 0:
                parcela <- d * PR[u] / grauSaída(u)
                para cada vizinho de saída v de u:
                    novoPR[v] <- novoPR[v] + parcela
            senão:
                distribuir d * PR[u] / N entre todos os vértices

    PR <- novoPR

    retornar PR
```

Na execução efetiva, a iteração e o tratamento de vértices sem saída são realizados internamente por `gds.pageRank`. O script `neo4j/pagerank.py` é responsável por criar a projeção apropriada, executar o algoritmo, gravar os escores na propriedade `pageRank` e exportar o ranking para TSV.

5.3 Projeções avaliadas

O primeiro experimento executou o PageRank sobre o grafo completo, preservando a orientação natural das relações. Esperava-se encontrar, nas primeiras posições, figuras semelhantes às observadas no núcleo exploratório da Figura 3, como Immanuel Kant, Leo Strauss e Karl Marx. O ranking obtido, entretanto, foi bastante diferente: além de instituições, religiões e áreas do conhecimento, sua primeira posição geral foi ocupada por Vasko Tolev, figura búlgara associada à religião e à teologia [5], com escore 488,2684.

A investigação desse resultado mostrou que o PageRank não mede diretamente notoriedade histórica ou grau no núcleo visualizado. Ele modela um fluxo de prestígio que percorre as arestas na direção projetada, de modo que tanto o tipo quanto a orientação de uma relação determinam onde a pontuação se acumula. No subgrafo, Tolev recebe arestas `INFLUENCED` de oito tradições religiosas ou mitológicas. Entre elas, *Islam* possui 3.004 arestas de entrada, PageRank 302,2443 e apenas uma aresta de saída; *Christianity* possui 2.617 arestas de entrada, PageRank 223,9322 e também apenas uma saída. Como essas saídas apontam para Tolev, os dois vértices transferem a ele, respectivamente, cerca de 256,91 e 190,34 pontos após a aplicação do fator de amortecimento. Forma-se, assim, um funil no qual a centralidade acumulada por conceitos religiosos é quase integralmente direcionada a uma única pessoa.

Esse diagnóstico motivou a criação de projeções específicas e o teste da inversão das relações pessoais. Foram definidos três cenários para investigar o efeito da seleção e da orientação das arestas.

Baseline. A projeção inclui os nove tipos finais de relacionamento, em suas orientações naturais. Esse experimento mede centralidade global no grafo heterogêneo e serve como referência para as demais configurações.

Pessoas. A projeção inclui somente INFLUENCED, DOCTORALSTUDENT e ACADEMICSTUDENT, todos com orientação invertida pelo GDS. No arquivo final, essas relações apontam do mentor para o discípulo. Para o PageRank, porém, essa direção transfere pontuação ao discípulo. A inversão faz a caminhada seguir do discípulo para o mentor, permitindo interpretar o escore como prestígio recebido de pessoas influenciadas ou orientadas. No caso de Tolev, as arestas passam a sair dele em direção aos conceitos religiosos, eliminando o funil observado no baseline e aproximando o ranking da interpretação desejada de influência intelectual.

Institucional. A projeção inclui INFLUENCED, DOCTORALSTUDENT, ACADEMICSTUDENT e ALMAMATER em orientação natural. A relação ALMAMATER aponta da pessoa para a instituição; portanto, universidades acumulam prestígio proveniente de seus ex-alunos. As relações pessoais foram mantidas para preservar caminhos de influência e formação antes da transferência para as instituições.

Tabela 4: Configuração dos experimentos de PageRank.

Experimento	Relações	Orientação
Baseline	Todos os nove tipos finais	Natural
Pessoas	INFLUENCED, DOCTORALSTUDENT, ACADEMICSTUDENT	Invertida
Institucional	As três relações anteriores e ALMAMATER	Natural

6 Avaliação do PageRank

6.1 Referência para pessoas

O ranking de pessoas foi comparado a uma referência construída a partir da Stanford Encyclopedia of Philosophy (SEP), enciclopédia acadêmica mantida pela Universidade Stanford [6]. Inicialmente, o script `analysis/filter_dbpedia_people.py` consultou o endpoint SPARQL da DBpedia em lotes e manteve apenas recursos classificados como pessoa. As respostas foram armazenadas em cache para permitir a retomada do processo sem repetir consultas. Esse filtro produziu 3.936 candidatos válidos.

A referência externa foi construída pelo script `analysis/build_sep_citation_ranking.py`, responsável pela raspagem automatizada das entradas da SEP. O programa parte da página de conteúdos da enciclopédia, coleta os endereços de todas as páginas sob `/entries/` e baixa seus documentos HTML. Para reduzir tráfego e tornar a execução retomável, cada página é armazenada em um cache local identificado pelo hash da URL; entre novos downloads, aplica-se ainda um intervalo de 0,5 segundo. A análise dos arquivos já armazenados é paralelizada entre os processadores disponíveis.

Antes do casamento dos nomes, o texto HTML é convertido para texto simples, com remoção de elementos de navegação, cabeçalhos, rodapés, scripts e estilos. Tanto o conteúdo quanto os rótulos dos candidatos passam por normalização Unicode, remoção de acentos e uniformização de espaços. O script também remove qualificadores finais de desambiguação, como “(philosopher)”, e corrige rótulos com tokens repetidos. Para cada candidato, utiliza-se o nome completo como alias principal; o sobrenome é aceito como alias secundário somente quando é suficientemente longo, não corresponde a uma palavra comum e não aparece em outro candidato. Expressões regulares com limites de palavra evitam correspondências dentro de termos maiores.

Para cada candidato, contou-se em quantas entradas distintas da SEP ao menos um alias aparecia e quantas ocorrências brutas foram encontradas. O primeiro valor foi adotado como escore de referência, pois reduz o peso de repetições dentro de uma mesma página; a contagem bruta serviu como critério secundário de desempate. O arquivo resultante, `analysis/sep_citation_ranking.tsv`, também registra os aliases reconhecidos e até cinco exemplos de páginas correspondentes, permitindo auditar os resultados da raspagem.

Foram empregadas duas métricas. A correlação de Spearman compara a ordem dos candidatos comuns aos dois rankings. Já o $\text{Overlap}@k$ mede a fração de elementos compartilhados entre os k primeiros colocados do PageRank e da referência da SEP:

$$\text{Overlap}@k = \frac{|Top_k(PR) \cap Top_k(SEP)|}{k}. \quad (2)$$

O uso de $\text{Overlap}@k$ decorre da natureza simétrica dessa comparação: tanto o PageRank quanto a SEP produzem rankings, e a pergunta é quanto seus respectivos conjuntos $\text{Top-}k$ concordam. A SEP não é tratada como uma lista absoluta de respostas corretas, mas como uma ordenação externa com a qual se deseja medir concordância.

Essa referência não deve ser interpretada como medida absoluta de importância filosófica. A frequência de nomes na SEP depende de cobertura editorial, ambiguidades e do papel desempenhado por certos autores na

própria enciclopédia. Ela fornece, contudo, um critério externo reproduzível para comparar as duas projeções do mesmo grafo.

6.2 Referência para universidades

As universidades foram identificadas por palavras-chave em seus rótulos, como `university`, `college`, `polytechnic` e equivalentes em outros idiomas. Os resultados foram comparados ao Top 20 do Center for World University Rankings (CWUR) de 2026 [7]. Diferentemente da comparação entre pessoas, o Top 20 do CWUR foi tratado como um conjunto fixo de instituições relevantes. A $Precision@k$ corresponde, portanto, à proporção das k universidades mais bem colocadas pelo PageRank que pertencem a esse conjunto de elite:

$$Precision@k = \frac{|Top_k(PR) \cap Elite_{CWUR}|}{k}. \quad (3)$$

Essa métrica responde quantas das instituições recomendadas pelo algoritmo são consideradas relevantes pela referência. Por exemplo, $Precision@10$ igual a 100% significa que todas as dez primeiras universidades do PageRank pertencem ao Top 20 do CWUR; não significa que as vinte instituições da referência tenham sido recuperadas. A correlação de Spearman foi calculada separadamente entre as posições das universidades do CWUR encontradas no grafo.

O CWUR avalia universidades por critérios diferentes da centralidade desta rede e, por isso, funciona como referência aproximada, não como verdade fundamental. A comparação verifica se as relações de formação e influência recuperam instituições reconhecidas externamente.

7 Resultados e discussão do PageRank

7.1 Pessoas e intelectuais

A projeção reversa para pessoas apresentou resultados superiores ao baseline em todas as métricas. A correlação de Spearman aumentou de 0,230920 para 0,499841. O $Overlap@20$ passou de 0% para 35%, e o $Overlap@50$ passou de 4% para 40%.

Tabela 5: PageRank de pessoas comparado à referência da SEP.

Projeção	Spearman	Overlap@20	Overlap@50
Baseline	0,230920	0%	4%
Pessoas, relações invertidas	0,499841	35%	40%

Tabela 6: Dez primeiros candidatos válidos na projeção de pessoas.

Posição	Pessoa	Escore
1	Immanuel Kant	58,0966
2	Aristotle	50,1809
3	Plato	40,7841
4	Gottfried Wilhelm Leibniz	27,3950
5	Pythagoras	27,2734
6	Ferdinand von Lindemann	25,6811
7	Parmenides	23,4694
8	Heraclitus	23,0318
9	Bertrand Russell	20,3374
10	David Hume	19,7355

O ganho confirma que a orientação semântica das arestas é decisiva. No baseline, relações heterogêneas fazem a pontuação fluir para instituições, religiões, áreas e obras. Na projeção de pessoas, a remoção dessas relações reduz a competição com entidades que não são indivíduos, enquanto a inversão direciona prestígio de discípulos para mentores. Kant, Aristóteles e Platão passam a ocupar as primeiras posições, em maior concordância com a referência externa.

A correlação permanece abaixo de uma concordância perfeita. Isso é esperado porque os critérios não são equivalentes: o PageRank mede posição estrutural nas relações registradas pela DBpedia, enquanto a

referência mede presença textual nas entradas da SEP. O aparecimento de Ferdinand von Lindemann entre os dez primeiros, por exemplo, indica que cadeias acadêmicas muito documentadas podem elevar candidatos cuja presença na tradição filosófica é mais restrita. Esse caso evidencia tanto a informação capturada pelo grafo quanto o viés de cobertura de suas relações.

7.2 Universidades

Para universidades, o baseline obteve Precision@10 de 100%, enquanto a projeção institucional atingiu 90%. Ambas alcançaram Precision@20 de 65%. A correlação com a ordem do CWUR também foi ligeiramente maior no baseline: 0,545865 contra 0,526316.

Tabela 7: PageRank de universidades comparado ao CWUR 2026.

Projeção	Precision@10	Precision@20	Spearman
Baseline	100%	65%	0,545865
Institucional	90%	65%	0,526316

Tabela 8: Dez primeiras universidades na projeção institucional.

Posição	Universidade	Escore
1	Harvard University	318,0176
2	University of Michigan	288,3303
3	Princeton University	244,0913
4	Yale University	220,1037
5	Columbia University	189,7218
6	University of Chicago	146,7403
7	University of Cambridge	141,6175
8	University of California, Berkeley	138,6354
9	Stanford University	135,5410
10	Hebrew University of Jerusalem	129,1625

A projeção institucional concentrou as primeiras posições em universidades reconhecidas, demonstrando que ALMAMATER oferece um sinal relevante de prestígio. Entretanto, ela não superou o baseline segundo as métricas adotadas. Isso sugere que as demais relações do grafo completo também carregam informação útil para instituições ou que a composição institucional escolhida ainda preserva ruído suficiente para alterar as primeiras posições.

Os resultados mostram que uma projeção especializada não é automaticamente superior. No caso de pessoas, a direção original contrariava o fluxo de prestígio desejado e sua inversão produziu ganho expressivo. No caso institucional, ALMAMATER já possuía a direção adequada, e a restrição do conjunto de relações não trouxe melhora mensurável. A seleção das arestas deve, portanto, ser fundamentada na semântica de cada relação e validada empiricamente.

Referências

- [1] DBpedia Association. *About DBpedia*. URL: <https://www.dbpedia.org/about/> (acesso em 22/06/2026).
- [2] DBpedia Association. *Mapping-based Objects: English, snapshot 2022-12-01*. 2022. URL: https://databus.dbpedia.org/dbpedia/mappings/mappingbased-objects/2022.12.01/mappingbased-objects_lang=en.ttl.bz2 (acesso em 22/06/2026).
- [3] Lawrence Page et al. “The PageRank Citation Ranking: Bringing Order to the Web”. Em: *The Web Conference*. 1999. URL: <https://www.semanticscholar.org/paper/The-PageRank-Citation-Ranking-%3A-Bringing-Order-to-Page-Brin/eb82d3035849cd23578096462ba419b53198a556> (acesso em 21/06/2026).
- [4] Neo4j. *PageRank — Neo4j Graph Data Science*. URL: <https://neo4j.com/docs/graph-data-science/current/algorithms/page-rank/> (acesso em 22/06/2026).
- [5] DBpedia Association. *About: Vaklush Tolev*. URL: https://dbpedia.org/page/Vaklush_Tolev (acesso em 22/06/2026).

- [6] Stanford University. *Stanford Encyclopedia of Philosophy*. URL: <https://plato.stanford.edu/> (acesso em 22/06/2026).
- [7] Center for World University Rankings. *World University Rankings 2026*. 2026. URL: <https://cwur.org/2026.php> (acesso em 22/06/2026).